공분산

와 para , implic 차이없음

point to point → error 설명

→ 확률론적 모델 도입 MLE 사용

가우시안 하고 해서 distance 도 가우시안 따른다.

log 해서 덧셈가능, 상수 날림

same with standard ICP (point to point)

(〃 (〃 plane)

⇒ 센서는 잘못 찍을수 있으니 ⇒ 확률적 모델 도입

⇒ 센서에 맞는 공분산 알아내서 점들에 (error) 적용하기

⇒ 공분산 행렬 왜 ?

교수님

⇒ $(x, y, z, \theta, \phi, \psi)$ 6자유도

측정했다!

$a_i \sim N(\hat{a}_i, C_i^A)$

object_val T_val noise

→ 많은 변수들이 있어서 확률모델 도입

$\overline{(x, y, z, \theta, \rho, \varphi)}$ → x,y,z 회전

↳ x,y는 오차크고, z는 오차작음

↓ 분산 큼 ↓ 분산 작음

⇒ ∴ x,y noise는 커서 조금이상해도 그렇구나
z는 이상하면 문제이 났구나

$$\boxed{T = \operatorname{argmin} \sum (d_i^T) \left(\underbrace{C_i^B + (T^*) C_i^A (T^*)^T}_{} \right)^{-1} (d_i^T)^T}$$

↳ 분산 고려 ⇒ error 최소화 하겠다
(공분산 행렬)

↳ 관측해서 얻거나 피사에서 준다
우리가 안줌아~

⇓

$$\frac{(x-x')^2}{\Delta_x^2} + \frac{(y-y')^2}{\Delta_y^2}$$

얘네들을 고려하는 이유,
→ Δ 들을 조절해 오차가 큰 변수는 가중치를 줄인다.

(소스와 타겟의 분산)

평면→평면 좋다
하지만 곡선 고려 못함

(indoor
outdoor) 나누어 본다.

Summary

- Contribution

=> 센서들 오차였으니. 그에맞는 공분산 행렬 알아내 이를 적용하는 확률적 모델 도입

- 확률 모델

=> 센서는 많은것을 측정. $x, y, z, \theta, \rho, \phi$ 가 있음.

=> 회사에서 우리센서는 z는 정확, x, y는 잘못해. 그래서 Covari Mat 를 그에 맞게 줘서 보정 해주는 것

즉, z가 조금 이상 => 큰일!, x, y 이상 => 아 원래 자꾸 오류나니 ㄱㅊ

- $e \Sigma^{-1} e^T$

=> 공분산 행렬을 이용해 위의 확률 모델을 도입한식 (3×3으로 예든것. 회전등 정보 더 있을수도)

$$(7 \quad 3 \quad 2) \begin{pmatrix} \frac{1}{18} & 0 & 0 \\ 0 & \frac{1}{5} & 0 \\ 0 & 0 & \frac{1}{3} \end{pmatrix} \begin{pmatrix} 7 \\ 3 \\ 2 \end{pmatrix} \Rightarrow$$

5,3에 비해

=> 대각성분은 $\frac{1}{\text{분산}}$ 이다. 즉 x값은 분산이 18로 크니 $\frac{1}{18}$ 만큼 조금만 반영하겠다

=> 주로 xy, xz 등의 성분은 0이다. x, y, z 등 단일로 측정하기 때문

Point to plane 같은 경우는 normal 방향 고려하는데

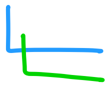 와 같은 경우 멈춰버림 하지만 G_ICP는 가우시안

고려 (x,y,z,..) 하여 이러한 현상이 안일어나서 진행됨

식보면 C_A, C_B 가 있는데 Covariance matrix 이다

C=0 이면 고려안함   C=I 면 서로 독립임!

$$\begin{pmatrix} x \\ y \\ z \\ \vdots \end{pmatrix} \begin{pmatrix} 0 & 0 & 0 & \cdots \\ 0 & 0 & 0 & \cdots \\ 0 & 0 & 0 & \\ & \vdots & & \ddots \end{pmatrix} \Rightarrow$$

x,y,z 서로 얼마나 영향주는지 세팅할수 있고, slam data 같은 것은 z는 거의 영향 없으니 그런것을 고려하여 Covariance matrix 고려해 설정하면 성능이 좋아진다

Normal distribution (가우시안)

$$f(x) = \underbrace{\frac{1}{\sqrt{2\pi}\,\sigma}}_{②}\ \underbrace{e}_{①}^{\ \underbrace{-\frac{(x-\mu)^2}{2\sigma^2}}_{③}} \qquad (-\infty < x < \infty)$$

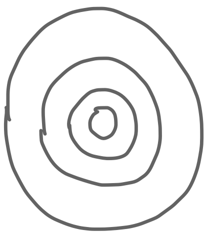

⇒ 확률 밀도 함수는 회전각의 변화에 독립

⇒ 중앙에서 거리가 같다면 넓이큰 영역에 많은 기대값 ↑

⇒ 넓이 같다면 중앙에 가까울수록 확률 높음

③ ⇒

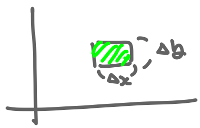

⇒ $f(x)\Delta x\, f(y)\Delta y = g(r)\,\Delta x\,\Delta y$ $f(x)$는 확률 밀도 함수

$g(r) = f(x)f(y)$ 회전에 대해 독립 (회전해도 확률 같음 like 과녁)

$$\frac{df(x)}{dx}\times\frac{dx}{d\theta}f(y) + f(x)\frac{df(y)}{dy}\frac{dy}{d\theta}$$

$$f'(x)(-y)f(y) + f(x)f'(y)x = 0 \qquad \frac{x f(x)}{f'(x)} = \frac{y f(y)}{f'(y)} = C$$

우리는 x에 대해서만 봄 $\quad x = C\frac{f'(x)}{f(x)} \Rightarrow \frac{1}{2}x^2 = C\ln f(x) + C'$

$$\therefore\ f(x) = Ae^{\frac{1}{2}ax^2}$$

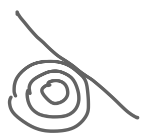

⇒ 음으로 C는 음수임!

② $\Rightarrow$ $\dfrac{1}{\sigma\sqrt{2\pi}}$ 유도

확률 밀도함수는 넓이 1이다. 즉 $\displaystyle\int_{-\infty}^{\infty} A_0 e^{-\frac{1}{2}kx^2} = 1$

즉, $\displaystyle\int_{-\infty}^{\infty} e^{-\frac{1}{2}kx^2}\,dx = \frac{1}{A_0} = I$

$$I^2 = \iint e^{-\frac{1}{2}k(x^2+y^2)}\,dx\,dy = \int_0^{2\pi}\int_0^{\infty} e^{-\frac{1}{2}kr^2}\,r\,dr\,d\theta$$

$-\frac{1}{2}kr^2 = u$. 라고 치환 하면 $\displaystyle\int_0^{2\pi}\int_0^{-\infty} e^{u}\left(-\frac{1}{k}\right)du\,d\theta = \frac{2\pi}{k}$

$\therefore A_0 = \sqrt{\dfrac{k}{2\pi}}$ $\Rightarrow$ $f(x) = \sqrt{\dfrac{k}{2\pi}}\, e^{-\frac{1}{2}kx^2}$

③ $\Rightarrow$ $f(x)$에 대해서, (→ 확률 밀도함수) $\mu = \displaystyle\int_{-\infty}^{\infty} x f(x)\,dx$ $\Rightarrow$ 기함수×우함수이라 $\mu = 0$이다

$$\sigma^2 = \int_{-\infty}^{\infty} x^2 f(x)\,dx$$

$\sqrt{\dfrac{k}{2\pi}}\displaystyle\int_{-\infty}^{\infty} \overset{u}{x}\,\overbrace{x e^{-\frac{1}{2}kx^2}}^{dv}\,dx$ ~ $\Rightarrow$ $k = \dfrac{1}{\sigma^2}$ 이다.

$x \Rightarrow x-\mu$ 로 이동 하면 $f(x) = \dfrac{1}{\sigma\sqrt{2\pi}}\, e^{-\frac{(x-\mu)^2}{2\sigma^2}}$