


Summary



) => 오류독성이이며
오류를 최소화 하려함

Land mark = 로봇이 공간상에서 독립하게 구별가능한 위치 (지나가는 공중도 Land/Mark)

(카메라 = 보류 보서, 저쪽
거리센서 = 지물의 위치

K = 시간!!

x_k (state vector) K시간에서 로봇의 공간상 위치와 방향을 담은 벡터

u_k (control vector) x_k 를 결정하는 명령벡터로, K-1 시간에 입력되어 K 시간에 출력됨

m_i (i는 랜덤 순서) = 특정시간 존재했던 로봇이 탐색한 랜드마크의 집합 (푸른 값)

z_{ik} (measurement) = 특정시간 K에서 로봇이 찾아낸 랜드마크의 집합 (z_k 라고하기도)
라고도 함

↳ i-th landmark at time K. (관측 값)

$x_{0:k} = \{x_0, x_1, \dots, x_k\} = \{x_{0:k-1}, z_k\} \Rightarrow$ history of vehicle location

$u_{0:k} = \{u_0, u_1, \dots, u_k\} = \{u_{0:k-1}, u_k\} \Rightarrow$ history of control inputs.

$m = \{m_1, m_2, \dots, m_n\} \Rightarrow$ set of landmark

$z_{0:k} = \{z_1, z_2, \dots, z_k\} = \{z_{0:k-1}, z_k\} \Rightarrow$ the set of all landmark observation

=> SLAM => $P(x_k, u)$ 내 위치, 측정된 LandMark 상태

Probabilistic SLAM

$x_{:k}, M$ 을 $P(x_k, m | Z_{0:k}, U_{0:k}, x_0)$ 로 구한다

↳ 시각시간부터 k 시간까지 모든 특징, 명령, 상태변수 등의 집합을 이용

• Observation model (관측 모델)

$P(Z_k | x_k, M) \Rightarrow$ 현재 위치, 역대 LandMark들로 새로운 LandMark 관측

• motion model (이동 모델)

$P(x_k | x_{k-1}, u_k) \rightarrow$ 이전 위치 벡터, 명령 벡터를 지금 위치 벡터 추론

↳ 객관 데이터 기반 이론, \therefore Markov Process

\rightarrow independent with observation model, 이를 Probabilistic Generative Law라 부른다.

Bayes filter (예측 & 수정)

• prediction (time - update)

$$P(x_k, m | Z_{0:k-1}, U_{0:k}, x_0) = \int P(x_k | x_{k-1}, u_k) \times P(x_{k-1}, m | Z_{0:k-1}, U_{0:k-1}, x_0) dx_{k-1}$$

* Bayes

$$P(x|y) = \frac{P(y|x)P(x)}{P(y)}$$

• Correction (measurement - update)

$$P(x_k, m | Z_{0:k}, U_{0:k}, x_0) = \frac{P(Z_k | x_k, m) P(x_k, m | Z_{0:k-1}, U_{0:k}, x_0)}{P(Z_k | Z_{0:k-1}, U_{0:k})}$$

Bayesian rule

$$\rightarrow P(A|B) = \frac{P(B|A) P(A)}{P(B)}$$

→ 데이터가 주어지기 전 어느정도 확률값을 예측하고 있을 때 새로 수집한 정보를 합쳐 결과 내어줌

→ 데이터를 계속 추가적으로 얻는 정도 여건 불확실성 이용해서 (전체 정보 불필요 x) 업데이트 하면서 다음 이용 가능

$P(A)$ (prior, 사전확률) = 사건 B가 발생하기 전 A의 확률

$P(A|B)$ (posterior, 사후확률) = 사건 B가 발생한 후 갱신된 사건 A의 확률

↳ 우리가 알고 싶은 것

$P(B)$ (normalizing const, evidence) = 정규화 상수, 증거

$P(B|A)$ (likelihood) = 사건 A가 발생한 경우 사건 B 확률

⇒ 사건 B가 발생하면서 ($P(B)=1$ 임을, 진실임을 알게 되면서) A의 확률이 어떻게 변하는지 표현한 정리, 즉 새로운 정보가 기존 추론에 어떻게 영향을 미치는지 표현

$$P(S) \quad P(A, B) = P(A|B) P(B) = P(B|A) P(A)$$

↳ A, B가 동시에 발생할 확률 $P(A \cap B)$

$$P(A|B) = \frac{P(B|A) P(A)}{\sum_i P(B|A_i) P(A_i)}$$

(ex) 병에 걸린 사람 양성일 확률 99% = $P(S|D)$

$P(S)$ = 양성
 $P(D)$ = 병 걸림

↳ 국가 전체 전체 인구를 0.2%가 걸림 $\Rightarrow P(D) = 0.002$

병에 안 걸린 사람이 양성 나올 확률 5% $\Rightarrow P(S|D^c) = 0.05$

$$\begin{aligned} P(D|S) &= \frac{P(S|D) P(D)}{P(S)} = \frac{P(S|D) P(D)}{P(S|D) P(D) + P(S|D^c) P(D^c)} = \frac{P(S|D) P(D)}{P(S|D) P(D) + P(S|D^c) (1-D)} \\ &= 0.99 \times 0.002 / (0.99 \times 0.002 + 0.05 \times (1-0.002)) = \underline{0.038} \end{aligned}$$

EKF

베이스 필터 \rightarrow 칼만 필터 \rightarrow 확장 칼만 필터

multivariable Gaussian distribution을 사용 x 가 k 개 요소로 구성

$$f_x(x_1, \dots, x_k) = \frac{1}{\sqrt{(2\pi)^k |\Sigma|}} e^{-\frac{1}{2}(x-\mu)^T \Sigma^{-1}(x-\mu)}$$

{

2.2 EKF에서 칼만 필터는 자세를 관리하게 된다.

Q x_k, v_k, m_k 는 어떤 성질을 가리키는가 (v_k 는 방향 벡터 란 조건 필요? 개인적으로는
이게 표현되는지).
 \Rightarrow 로봇 자기 위치를 $(0,0,0)$ 이라 하는지
 아니면 지도상 $(0,0,0)$ 기준점을 정하고 위치를 측정하는지

A_{ns} $v_{-k} \rightarrow$ $0, 1, 2, \dots$ 로 여러 방향으로 얼마만큼 갔는지 알려줌

$\Rightarrow x_k = 0,0,0$ 을 x_0 이라 하고 거기서 좌표들의 값

$\Rightarrow z_{i,k} = z_i$ 인 상태에서 (z_i) 를 기준으로 z_k 값들 (랜드마크 값들을
받은 것)

☆ m 에 대한 association 즉, 어디서 어떤 물체에서 나온
관측 값인지를 알고 한다 (예외, 라인드 폐쇄될지 랜덤하고 구분하기 하고있다)

\Rightarrow 즉 논문은 data association 100% 라 가정되어 있다.

↓
이 값은 A의 값의 값
이 값은 B의 값의 값

↳ 이게 틀리면 어떻게 해야 할까?

↳ m 이 틀리면? $P(z_i | x_k, m) \rightarrow$ 바꿔쳐야 한다.

\Rightarrow SLAM 정의는 다양하다고 말씀. a team 아닌 것처럼 되고, loop closing 이
되냐 안되냐를

(trajectory \Rightarrow 로봇 궤적 + 속도 정보 (즉 시간까지)
 path \Rightarrow 그냥 단순 길