

평균 필터 (average filter)

⇒ 데이터를 다져놓아서 컴퓨터 (필터, 즉가데이터, 데이터 저장장치) 이용

$$\bar{x}_k = (x_1 + x_2 + \dots + x_k) / k \quad \Rightarrow \quad \bar{x}_k = \frac{k-1}{k} \bar{x}_{k-1} + \frac{1}{k} x_k$$

이동 평균 필터 (moving average filter)

⇒ 너무 오래된 데이터는 고려 안하고 싶어 최근 몇개의 측정값만 가지고 평균 냄

$$\bar{x}_k - \bar{x}_{k-1} = \frac{x_k - x_{k-n}}{n} \quad \Rightarrow \quad \bar{x}_k = \bar{x}_{k-1} + \frac{x_k - x_{k-n}}{n}$$

↳ n개 data 고려

저주파 통과 필터 (low pass filter)

⇒ n개 데이터보다도 최근치에 가중치를 두고 냄

• 1차 저주파 : $\bar{x}_k = \alpha \bar{x}_{k-1} + (1-\alpha) x_k$ (이전평균 \times 가중치 + 새데이터 \times (1-가중치))

$$= \alpha(\alpha \bar{x}_{k-2} + (1-\alpha) x_{k-1}) + (1-\alpha) x_k$$

↳ $0 < \alpha < 1$ 일수록 $\bar{x}_k \dots$ 점점 이전 영향은 α^n 으로 나이 늘어나며 영향도 작아진다.

(α 가 작다 : 노이즈는 많지만 변화에 민감 (α^n 이 너무 작아 감도없으면 바로 반영)
 α 가 크다 : 노이즈는 적지만 변화에 둔감 (α^n 이 1에 가까워 가중치 비슷)
 ↳ 이와 새로운 이상한 값에도 (노이즈) 반영 비율 작아 노이즈 격함

Localization and tracking

z_t = t지점 센서 값, u_t = t지점 control input 값

local화라고
한마디로
말함

(Localization $bel(z_t) = p(x_t | z_{1:t}, u_{1:t})$ Control input 있음
 Tracking $bel(x_t) = p(x_t | z_{1:t})$ Control input 없음 \rightarrow 바뀐 예시
 Control input 없어도

상태 방정식 (State equation)

Control input 제어입력
noise

$$x(k) = x(k-1) + T \dot{x}(k-1) + \frac{T^2}{2} \ddot{x}(k-1) + \frac{T^2}{2} (u(k) + w(k))$$

$$\dot{x}(k) = \dot{x}(k-1) + T \ddot{x}(k-1) + T(u(k) + w(k))$$

$$\ddot{x}(k) = \ddot{x}(k-1) + (u(k) + w(k))$$

$$z(k) = x(k) + v(k)$$

↓
MM data

↓

↳ 2DZ

↗ State matrix

↗ Control matrix

• State eq $\Rightarrow \begin{bmatrix} x(k) \\ \dot{x}(k) \\ \ddot{x}(k) \end{bmatrix} = \begin{bmatrix} 1 & T & T^2/2 \\ 0 & 1 & T \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x(k-1) \\ \dot{x}(k-1) \\ \ddot{x}(k-1) \end{bmatrix} + \begin{bmatrix} T^2/2 \\ T \\ 1 \end{bmatrix} (u(k) + w(k))$

• measure eq $\Rightarrow z(k) = [1 \ 0 \ 0] \begin{bmatrix} x(k) \\ \dot{x}(k) \\ \ddot{x}(k) \end{bmatrix} + v(k)$

↓
- transition matrix

↓

$$x(k) = A x(k-1) + B (u(k) + w(k))$$


$$z(k) = C x(k) + v(k)$$

Bayes Rule

Discrete $p(x|b) = \frac{p(b|x) p(x)}{p(b)} = \frac{p(b|x) p(x)}{\sum p(b|x') p(x')}$

Continuous $p(x|b) = \frac{p(b|x) p(x)}{p(b)} = \frac{p(b|x) p(x)}{\int p(b|x') p(x) dx}$

Base Filter



→ 로봇이 움직이지 않더라도 판단 가능. 차이에 레이더 돌리면 문으로 인해서 Gauss 분포 생김

⇒ 움직이면 로봇을 따라가거나 분포 넓이가 넓어진다. (smooth)

⇒ 움직이고 다시 radar 쏘으면 이전 고려한 분포와 새 측정에서
 라이다 정보 통해 자신 위치를 갱신함 (과거 위치 + 현재 위치 ⇒ 예측)

∴ recursive, iterative 하게 현재 위치 추론 → Bayes Filter

$bel(x_t) = p(z_t | x_t, z_{1:t-1}, u_{1:t})$ 지금까지 landmark, control vec 으로 위치추론
 (물리적 위치, 이동정보)

베이지스 룰 적용 ⇒
$$\frac{p(z_t | x_t, z_{1:t-1}, u_{1:t}) \times p(x_t | z_{1:t-1}, u_{1:t})}{p(z_{1:t}, u_{1:t})}$$
 → 상. land, convect 이며 다른 값
 (근거나용)

$$= \eta \frac{p(z_t | x_t, z_{1:t-1}, u_{1:t}) p(x_t | z_{1:t-1}, u_{1:t})}{\text{상.}}$$

$$= \eta \frac{p(z_t | x_t) p(x_t | z_{1:t-1}, u_{1:t})}{\text{상.}}$$
 → $(z_t, x_t, u_{1:t}$ 와 관련 X. (Markov assumption))

$$= \eta p(z_t | x_t) \int p(x_t | z_{t-1}, u_{1:t}) p(z_{t-1} | z_{1:t-1}, u_{1:t}) dz_{t-1}$$
 → x_{t-1} 이 존재하는건 recursive, 이전정보로 추정 가능하다. (Low or total probability)

$$= \eta p(z_t | x_t) \int p(x_t | z_{t-1}, u_{1:t}) p(z_{t-1} | z_{1:t-1}, u_{1:t-1}) dz_{t-1}$$
 → z_t 는 x_t 와 무관
 모든 convect 은 필요, 딱 이전만 필요

$$= \eta p(z_t | x_t) \int p(x_t | z_{t-1}, u_{1:t}) bel(x_{t-1}) dz_{t-1}$$
 → $u_{1:t-1}$ 에 영향 X, $u_{1:t} \rightarrow u_{1:t-1}$ 오

Bayes filter 개념적 정리

$$\eta p(z_{t+1} | x_t) \bar{bel}(x_t)$$

$$bel(x_t) = \eta p(z_{t+1} | x_t) \times \int p(x_{t+1} | x_t, u_t) \bar{bel}(x_t) dx_t$$

③

②

$$\bar{bel}(x_{t+1})$$

⇒ 이전 state (확률분포) 정보에 측정 operation 으로 현재 시점에

⇒ 즉, 과거 $bel(x_{t-1})$ 에서 u_t 현재 control 이용하면 x_t 예측한다.

$$p(x) = \int p(x|y) p(y) dy$$

① ⇒ Motion model : control로 현재 state 예측

② ⇒ Prediction step : 예측한 것 = $\bar{bel}(x_t)$ 이다.

③ ⇒ Correction step : predic \bar{bel} + observation 정보로 조정해준다.
(Observation model) $\eta p(z_t | x_t)$

Fun ($bel(x_{t-1}), u_t, z_t$) :

for x_t do


$$\bar{bel}(x_t) = \int p(x_t | u_t, x_{t-1}) \bar{bel}(x_{t-1}) dx_{t-1}$$

$$bel(x_t) = \eta p(z_t | x_t) \bar{bel}(x_t)$$

end for

return $bel(x_t)$

(motion model : $p(x_t | x_{t-1}, u_t)$
sensor model : $p(z_t | x_t)$)



① ⇒ 이전 상태

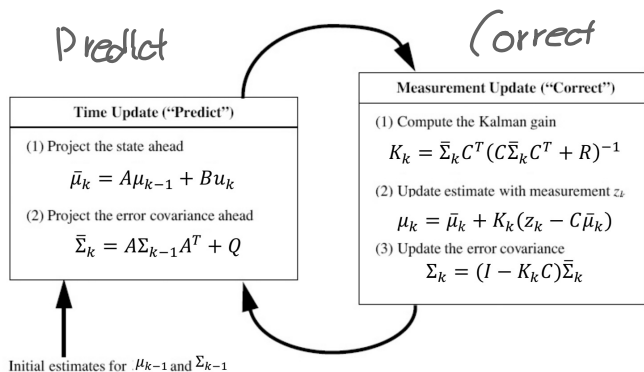
② ⇒ $p(x_t | u_t, x_{t-1})$ 이전 상태와 제어값이 주어졌을 때 현재 상태 확률 분포

③ ⇒ $\bar{bel}(x_t)$ ⇒ control update (prediction)

④ ⇒ $p(z_t | x_t)$: 현재 상태의 센서값의 확률 분포

⑤ ⇒ $bel(x_t)$: measurement update (correction)

칼만 필터



0. 초기값 설정

$$\hat{x}_0, P_0$$

1. 예측값, 공분산오차 예측

$$\hat{x}_k^- = A \hat{x}_{k-1}$$

$$P_k^- = A P_{k-1} A^T + Q$$

→ 이전 step 값들 쓰인다
(recursive 하다)

→ A, Q는 정해져 있다

우리는 이전 값 (P_{k-1})로 P_k 계산함

2. 칼만이득 계산 (측정에 대한 불확실성)

$$K_k = P_k^- H^T (H P_k^- H^T + R)^{-1}$$

→ H, R도 정해져 2번에서 구한 P_k 로
K를 단순 계산

3. 측정값 계산

$$\hat{x}_k = \hat{x}_k^- + K_k (z_k - H \hat{x}_k^-)$$

→ 앞에서 구한 것들
→ $\boxed{} + z_k \rightarrow \hat{x}_k$
(측정값) (측정값)

4. 오차 공분산 계산

$$P_k = P_k^- - K_k H A P_k^-$$

→ 1~3에서 구한 값들로 오차 고려하는 것

⇒ 사실 A, H, Q, R 만 알면 칼만 필터는 그냥 계산 문제일

A, H 는 state space equation (상태공간 방정식)

Q, R 는 Noise 이다.

U_t = 로봇 위치, 라센 마크 위치 (State)

Σ = covariance matrix? (covariance matrix)

KF \Rightarrow 실제 parameter 들 계산 할수 없음을 보이기.

그냥 측정한 값을 가측치만으로 가정해서 parameter 계산 가능.

(p, θ)

회전 6도씩 하고 6도씩 이동 \Rightarrow 회전을 6도씩 한다

\Rightarrow 즉 $(\cos\theta, \sin\theta)$ 가 되어 EKF 필요

G, H \Rightarrow 기하학적 공식으로 선형화 하기

각각 x (각각 pose)

A, B = 각각 단위 행렬, C = 4개 landmark 위치

EKF

⇒ 칼만 필터는 로봇의 state 추정에 흔히 사용되는 방법이며, Bayes filter 일.

↳ control input 의한 prediction / 센서 observation 으로부터 correction

↳ KF는 linear 만도되나 non linear 한 EKF 가 4월

SLAM은 vector로 state, 센서입력, 환경값 등을 표현해

multi variable의 Gaussian을 많이 사용한다.

Gaussian distri $\Rightarrow p(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$

multi variable Gaussian dist $\Rightarrow p(x) = \frac{1}{\sqrt{\det(2\pi\Sigma)}} e^{-\frac{1}{2}(x-\mu)^T \Sigma^{-1}(x-\mu)}$