

평균 필터 (average filter)

⇒ 데이터를 다져놓아서 컴퓨터 (필터, 즉가데이터, 데이터 저장장치) 이용

$$\bar{x}_k = (x_1 + x_2 + \dots + x_k) / k \quad \Rightarrow \quad \bar{x}_k = \frac{k-1}{k} \bar{x}_{k-1} + \frac{1}{k} x_k$$

이동 평균 필터 (moving average filter)

⇒ 너무 오래된 데이터는 고려 안하고 싶어 최근 몇개의 측정값만 가지고 평균 냄

$$\bar{x}_k - \bar{x}_{k-1} = \frac{x_k - x_{k-n}}{n} \quad \Rightarrow \quad \bar{x}_k = \bar{x}_{k-1} + \frac{x_k - x_{k-n}}{n}$$

↳ n개 data 고려

저주파 통과 필터 (low pass filter)

⇒ n개 데이터보다도 최근치에 가중치를 두고 냄

• 1차 저주파 : $\bar{x}_k = \alpha \bar{x}_{k-1} + (1-\alpha) x_k$ (이전평균 \times 가중치 + 새데이터 \times (1-가중치))

$$= \alpha(\alpha \bar{x}_{k-2} + (1-\alpha) x_{k-1}) + (1-\alpha) x_k$$

↳ $0 < \alpha < 1$ 일수록 $\bar{x}_k \dots$ 점점 이전 영향도 α^n 으로 나뉘어 나감
영향도 작아진다.

(α 가 작다 : 느려지는 만리만 변화에 민감 (α^n 이 너무 작아 감도없으면 바로 반영)
 α 가 크다 : 느려지는 전지만 변화에 둔감 (α^n 이 1에 가까워 가중치 비슷)
 ↳ 아파 새로운 이상한 값이라도 (느임) 반영 비율 작아 느임 극한

Localization and tracking

z_t = t지점 센서 값, u_t = t지점 control input 값

local화라고
한국 (관찰)
같이

(Localization $bel(z_t) = p(x_t | z_{1:t}, u_{1:t})$ Control input 있음
 Tracking $bel(x_t) = p(x_t | z_{1:t})$ Control input 없음 \rightarrow 바뀐 예시
 Control input 없어도

상태 방정식 (State equation)

Control input 제어입력
noise

$$x(k) = x(k-1) + T \dot{x}(k-1) + \frac{T^2}{2} \ddot{x}(k-1) + \frac{T^2}{2} (u(k) + w(k))$$

$$\dot{x}(k) = \dot{x}(k-1) + T \ddot{x}(k-1) + T(u(k) + w(k))$$

$$\ddot{x}(k) = \ddot{x}(k-1) + (u(k) + w(k))$$

$$z(k) = x(k) + v(k)$$

↓
MM data

↓
SOLZ

↗ State matrix

↗ Control matrix

• State eq $\Rightarrow \begin{bmatrix} x(k) \\ \dot{x}(k) \\ \ddot{x}(k) \end{bmatrix} = \begin{bmatrix} 1 & T & T^2/2 \\ 0 & 1 & T \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x(k-1) \\ \dot{x}(k-1) \\ \ddot{x}(k-1) \end{bmatrix} + \begin{bmatrix} T^2/2 \\ T \\ 1 \end{bmatrix} (u(k) + w(k))$

• measure eq $\Rightarrow z(k) = [1 \ 0 \ 0] \begin{bmatrix} x(k) \\ \dot{x}(k) \\ \ddot{x}(k) \end{bmatrix} + v(k)$

↓
transition matrix

↓

$$x(k) = A x(k-1) + B (u(k) + w(k))$$


$$z(k) = C x(k) + v(k)$$

Bayes Rule

Discrete $p(x|b) = \frac{p(b|x) p(x)}{p(b)} = \frac{p(b|x) p(x)}{\sum p(b|x') p(x')}$

Continuous $p(x|b) = \frac{p(b|x) p(x)}{p(b)} = \frac{p(b|x) p(x)}{\int p(b|x') p(x) dx}$

Base Filter



→ 로봇이 움직이지 않더라도 판단 가능. 차이에 레이더 돌리면 문으로 인해서 Gauss 분포 생김

⇒ 움직이면 로봇을 따라가거나 분포 넓이가 넓어진다. (smooth)

⇒ 움직이고 다시 radar 쏘으면 이전 고려한 분포와 새 측정에서
라이다 정보 통해 자신 위치를 갱신함 (과거 위치 + 현재 위치 ⇒ 예측)

∴ recursive, iterative 하게 현재 위치 추론 → **Bayes Filter**

$bel(x_t) = p(x_t | z_{1:t}, u_{1:t})$ 지금까지 landmark, control vec 으로 위치추론
(물리적 위치, 이동정보)

베이지스 룰 적용 ⇒
$$\frac{p(z_t | x_t, z_{1:t-1}, u_{1:t}) \times p(x_t | z_{1:t-1}, u_{1:t})}{p(z_{1:t}, u_{1:t})}$$
 → 상. land, convect 이며 다른 값
(근거 사용)

$$= \eta \frac{p(z_t | x_t, z_{1:t-1}, u_{1:t}) p(x_t | z_{1:t-1}, u_{1:t})}{\text{상.}}$$

$$= \eta \frac{p(z_t | x_t) p(x_t | z_{1:t-1}, u_{1:t})}{\text{상.}}$$

→ $(z_t, x_t, u_{1:t})$ 와 관련 X. (Markov assumption)

$$= \eta p(z_t | x_t) \int p(x_t | z_{1:t-1}, u_{1:t}) p(z_{1:t-1} | z_{1:t-1}, u_{1:t}) dz_{1:t-1}$$

(필요시) z, u 는 2차원
 x_{t+1} 이 예측되는건데

$$= \eta p(z_t | x_t) \int p(x_t | z_{1:t-1}, u_{1:t}) p(z_{1:t-1} | z_{1:t-1}, u_{1:t}) dz_{1:t-1}$$

이는 recursive, 이전정보로
조정해준다. (Low or total probability)

$$= \eta p(z_t | x_t) \int p(x_t | z_{1:t-1}, u_{1:t}) p(z_{1:t-1} | z_{1:t-1}, u_{1:t}) dz_{1:t-1}$$

→ z 는 x_t 와 무관
모든 convect 은 필요, 딱 이전만 필요

$$= \eta p(z_t | x_t) \int p(x_t | z_{1:t-1}, u_{1:t}) bel(x_{t-1}) dz_{1:t-1}$$

→ $u_{1:t-1}$ 에 영향 X, $u_{1:t} \rightarrow u_{1:t+1}$

Bayes filter 개념적 정리

$$\eta p(z_{t+1} | x_t) \bar{bel}(x_t)$$

$$bel(x_t) = \eta p(z_{t+1} | x_t) \times \int p(x_{t+1} | x_t, u_t) \bar{bel}(x_t) dx_t$$

③

②

$\bar{bel}(x_t)$

⇒ 이전 state (확률분포) 정보에 측정 operation 으로 현재 시점에

⇒ 즉, 과거 $bel(x_{t-1})$ 에서 u_t 현재 control 이용하면 x_t 예측한다.

$$p(x) = \int p(x|y) p(y) dy$$

① ⇒ Motion model : control로 현재 state 예측

② ⇒ Prediction Step : 예측한 것 = $\bar{bel}(x_t)$ 이다.

③ ⇒ Correction Step : predic \bar{bel} + observation 정보로 조정해준다.
(Observation model) $\eta p(z_{t+1} | x_t)$

Fun ($bel(x_{t-1}), u_t, z_t$) :

for x_t do


$$\bar{bel}(x_t) = \int p(x_t | u_t, x_{t-1}) \bar{bel}(x_{t-1}) dx_{t-1}$$

$$bel(x_t) = \eta p(z_t | x_t) \bar{bel}(x_t)$$

end for

return $bel(x_t)$

(motion model : $p(x_t | x_{t-1}, u_t)$
sensor model : $p(z_t | x_t)$)



① ⇒ 이전 상태

② ⇒ $p(x_t | u_t, x_{t-1})$ 이전 상태와 제어값이 주어졌을 때 현재 상태 확률 분포

③ ⇒ $\bar{bel}(x_t)$ ⇒ control update (prediction)

④ ⇒ $p(z_{t+1} | x_t)$: 현재 상태의 센서값의 확률 분포

⑤ ⇒ $bel(x_t)$: measurement update (correction)

U_t = 로봇 위치, 라센 마크 위치 (State)

Σ = 무어대한 분산? (혹물도 업데이트한다.)

KF \Rightarrow 실제 parameter 들 계산 할수 없음을 보여줌.

그냥 추상적인 것을 가측치만으로 가정해서 parameter 계산 가능.

(p, θ)

회전 θ 만큼 하고 p 만큼 이동 \Rightarrow 회전을 θ 만큼 한다

\Rightarrow 즉 $(p \cos \theta, p \sin \theta)$ 가 되기에 EKF 필요

G, H \Rightarrow 더(덜)더 정확히 선형화 하기

저장 x (현재 pose)

A, B = 그냥 단위 행렬, C = N 개 Landmark 개리

EKF

=> 칼만 필터는 로봇의 state 추정에 흔히 사용되는 방법이며, Bayes filter 일.

↳ control input 의한 prediction / 센서 observation 으로부터 correction

↳ KF는 linear 만도되나 non linear 한 EKF 가 4월

SLAM은 vector로 state, 센서입력, 환경값 등을 표현해

multi variable의 Gaussian을 많이 사용한다.

Gaussian distri => $p(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$

multi variable Gaussian dist => $p(x) = \frac{1}{\sqrt{\det(2\pi\Sigma)}} e^{-\frac{1}{2}(x-\mu)^T \Sigma^{-1}(x-\mu)}$